

hw_6

April 26, 2025

```
[28]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import f_oneway, kruskal
from scipy.stats import gaussian_kde, ks_2samp
import os
import kagglehub
from sklearn.cluster import KMeans, DBSCAN
from scipy.cluster.hierarchy import dendrogram, linkage

from yellowbrick.cluster import KElbowVisualizer
path = kagglehub.dataset_download("mirichoi0218/insurance")

print("Path to dataset files:", path)
```

Warning: Looks like you're using an outdated `kagglehub` version, [please](#)
consider updating (latest version: 0.3.12)
Path to dataset files:
/Users/katiegalaeva/.cache/kagglehub/datasets/mirichoi0218/insurance/
versions/1

```
[29]: csv_file = os.path.join(path, "insurance.csv")

df_original = pd.read_csv(csv_file)
df_original.describe()
```

```
[29]:
```

	age	bmi	children	charges
count	1338.000000	1338.000000	1338.000000	1338.000000
mean	39.207025	30.663397	1.094918	13270.422265
std	14.049960	6.098187	1.205493	12110.011237
min	18.000000	15.960000	0.000000	1121.873900
25%	27.000000	26.296250	0.000000	4740.287150
50%	39.000000	30.400000	1.000000	9382.033000
75%	51.000000	34.693750	2.000000	16639.912515
max	64.000000	53.130000	5.000000	63770.428010

```
[30]: df_original.loc[df_original['smoker']=='yes']
```

```
[30]:
```

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
11	62	female	26.290	0	yes	southeast	27808.72510
14	27	male	42.130	0	yes	southeast	39611.75770
19	30	male	35.300	0	yes	southwest	36837.46700
23	34	female	31.920	1	yes	northeast	37701.87680
...	...	...	...	...	...	...	...
1313	19	female	34.700	2	yes	southwest	36397.57600
1314	30	female	23.655	3	yes	northwest	18765.87545
1321	62	male	26.695	0	yes	northeast	28101.33305
1323	42	female	40.370	2	yes	southeast	43896.37630
1337	61	female	29.070	0	yes	northwest	29141.36030

[274 rows x 7 columns]

1. Гипотеза

Увеличение физической активности (снижение bmi) у курящих людей снижает их медицинские расходы (charges).

H_0 : Средние расходы (charges) одинаковы у курящих с высоким и низким BMI.

H_1 : Средние расходы (charges) у курящих с высоким BMI больше, чем у курящих с низким BMI.

Метрика: Средние медицинские расходы (charges) у курящих с высоким bmi > расходов у курящих с низким bmi.

2. Дизайн эксперимента Цель: Проверить влияние снижения bmi на charges у курящих.

Параметры: - альфа = 0.05 - бета = 0.2 (мощность теста 80%) - effect_size, например, на 15% снижение расходов

Эмпирический метод: - Бутстрэп для оценки распределения метрик

3. Проведение эксперимента Фильтруем только курящих (smoker = yes) Делим их по медиане bmi: А-группа: bmi > медиана В-группа: bmi <= медиана Сравниваем charges в этих двух группах.

4. Как будем принимать решения Если средние расходы в группе В (меньший bmi) значимо ниже (p-value < 0.05), то гипотезу отвергаем. Если нет — гипотезу принимаем.

```
[31]: from scipy.stats import ttest_ind
from tqdm import tqdm
from statsmodels.stats.power import TTestIndPower
%matplotlib inline
sns.set(style="whitegrid")
```

```
[32]: df_smokers = df_original[df_original['smoker'] == 'yes'].copy()

median_bmi = df_smokers['bmi'].median()

group_A = df_smokers[df_smokers['bmi'] > median_bmi]
group_B = df_smokers[df_smokers['bmi'] <= median_bmi]

print(f"Размер A-группы: {len(group_A)}")
print(f"Размер B-группы: {len(group_B)}")
```

Размер A-группы: 137
Размер B-группы: 137

```
[33]: alpha = 0.05
power = 0.8

mean_charges = df_smokers['charges'].mean()
std_charges = df_smokers['charges'].std()

effect = 0.15 * mean_charges

effect_size = effect / std_charges

print(f"Стандартизированный размер эффекта (Cohen's d): {effect_size:.4f}")

analysis = TTestIndPower()
sample_size = analysis.solve_power(effect_size=effect_size,
    alpha=alpha, power=power, alternative='two-sided')

print(f"Необходимый размер выборки на каждую группу: {sample_size:.0f}")
```

Стандартизированный размер эффекта (Cohen's d): 0.4165
Необходимый размер выборки на каждую группу: 91

Размер группы больше необходимого: $137 > 91$ — значит, мощности эксперимента хватит с запасом. Это означает, что данных достаточно, чтобы уверенно поймать эффект такого размера (Cohen's $d \approx 0.42$) на уровне значимости 0.05 с мощностью 0.8 и выше. Следовательно, риск ошибки второго рода еще ниже, чем планировалось.

Бустрап

```
[34]: n_iterations = 10000
boot_diffs = []


for _ in tqdm(range(n_iterations)):
    boot_A = group_A['charges'].sample(frac=1, replace=True)
```

```
boot_B = group_B['charges'].sample(frac=1, replace=True)
diff = boot_A.mean() - boot_B.mean()
boot_diffs.append(diff)
```

```
plt.figure(figsize=(10,6))
sns.histplot(boot_diffs, kde=True)
plt.title('Бутстрэп распределение разницы средних (A - B)')
plt.xlabel('Разница средних charges')
plt.axvline(np.percentile(boot_diffs, 2.5), color='red',
            linestyle='--')
plt.axvline(np.percentile(boot_diffs, 97.5), color='red',
            linestyle='--')
plt.show()

conf_interval = np.percentile(boot_diffs, [2.5, 97.5])
print(f"95% доверительный интервал разницы средних: {conf_interval}")
```

100%|██████████| 10000/10000 [00:00<00:00, 18276.18it/s]



95% доверительный интервал разницы средних: [17967.03916524 20895.2549112]

```
[35]: t_stat, p_value = ttest_ind(group_A['charges'], group_B['charges'],
    equal_var=False)

print(f"T-статистика: {t_stat:.3f}")
print(f"p-значение: {p_value:.3f}")
```

T-статистика: 26.061
p-значение: 0.000

1 Выводы

1.0.1 95% доверительный интервал разницы средних:

- Интервал [17987, 20885] не включает ноль, значит разница действительно существенная.

1.0.2 t-тест:

- **t-статистика:** 26.061 — очень большое значение (сильно отличается от 0).
- **p-значение:** 0.000 — намного меньше уровня значимости $\alpha = 0.05$.

Это говорит о том, что отвергается нулевая гипотеза о равенстве средних:

- средние расходы действительно различаются между группами с разным уровнем BMI.

Среди курящих пациентов расходы на медицинское обслуживание статистически значимо ниже у пациентов с более низким BMI. Это может указывать на потенциальную возможность для страховых компаний и государственных программ сфокусироваться на работе с пациентами с высоким BMI, чтобы потенциально снизить общие расходы.